



Participez à un concours sur la Smart City

Projet 2 - Julien Agneray



Sommaire

1. Contexte du projet
2. Présentation du Jeu de Données
3. Démarche Méthodologique d'Analyse de Données
4. Synthèse de l'Analyse de Données



Contexte du projet

- L'ONG "Data is for Good", propose des challenges de Data Science en ligne sur des thématiques ayant trait au bien commun.
- Le challenge proposé par la ville de Paris nous demande de réaliser une analyse exploratoire avec un jeu de données portant sur les arbres de la ville.
- Nos résultats contribueront à une optimisation des tournées pour l'entretien des arbres de la ville.
- Un jeu de données des arbres de la ville de Paris est mis à notre disposition pour la réalisation du projet.

Présentation générale du jeu de données

	id	type_emplacement	domanialite	arrondissement	complement_adresse	numero	lieu	id_emplacement	libelle_francais	genre	espece	variete	circonference_cm	hauteur_m	stade_developpement	remarquable	geo_poi	
0	99874	Arbre	Jardin	PARIS 7E ARRD		NaN	MAIRIE DU 7E 116 RUE DE GRENELLE PARIS 7E	19	Marronnier	Aesculus	hippocastanum	NaN	20	5		NaN	0.0	48
1	99875	Arbre	Jardin	PARIS 7E ARRD		NaN	MAIRIE DU 7E 116 RUE DE GRENELLE PARIS 7E	20	If	Taxus	baccata	NaN	65	8		A	NaN	48
2	99876	Arbre	Jardin	PARIS 7E ARRD		NaN	MAIRIE DU 7E 116 RUE DE GRENELLE PARIS 7E	21	If	Taxus	baccata	NaN	90	10		A	NaN	48
3	99877	Arbre	Jardin	PARIS 7E ARRD		NaN	MAIRIE DU 7E 116 RUE DE GRENELLE PARIS 7E	22	Erable	Acer	negundo	NaN	60	8		A	NaN	48
4	99878	Arbre	Jardin	PARIS 17E ARRD		NaN	PARC CLICHY- BATIGNOLLES- MARTIN LUTHER KING	000G0037	Arbre à miel	Tetradium	daniellii	NaN	38	0		NaN	NaN	48



Présentation générale du jeu de données

Source des données :

Les données proviennent de la ville de Paris et sont disponibles sur opendata.paris.fr.

Description des données :

Le jeu de données contient 200,137 lignes et 18 colonnes. Il inclut des informations détaillées sur chaque arbre, telles que son emplacement, son espèce, sa circonférence et sa hauteur.

Exemples de colonnes :

- id : Identifiant unique de l'arbre
- domanialite : Classification du terrain sur lequel l'arbre est localisé.
- arrondissement : Zone géographique où l'arbre est localisé.
- circonference_cm : La circonférence de l'arbre en centimètre.



Présentation générale du jeu de données

	id	numero	circonference_cm	hauteur_m	remarquable	geo_point_2d_a	geo_point_2d_b
count	2.001370e+05	0.0	200137.000000	200137.000000	137039.000000	200137.000000	200137.000000
mean	3.872027e+05	NaN	83.380479	13.110509	0.001343	48.854491	2.348208
std	5.456032e+05	NaN	673.190213	1971.217387	0.036618	0.030234	0.051220
min	9.987400e+04	NaN	0.000000	0.000000	0.000000	48.742290	2.210241
25%	1.559270e+05	NaN	30.000000	5.000000	0.000000	48.835021	2.307530
50%	2.210780e+05	NaN	70.000000	8.000000	0.000000	48.854162	2.351095
75%	2.741020e+05	NaN	115.000000	12.000000	0.000000	48.876447	2.386838
max	2.024745e+06	NaN	250255.000000	881818.000000	1.000000	48.911485	2.469759



Présentation générale du jeu de données

Circonférence et Hauteur des Arbres :

Nous remarquons des valeurs minimales de 0 cm/m et des valeurs maximales de 250255 cm / 881818 m, indiquant clairement la présence de données aberrantes nécessitant un nettoyage méticuleux.

Présence de Valeurs Nulles :

Nous constatons que la colonne 'numero' contient exclusivement des valeurs manquantes, soulignant la nécessité de traiter ces absences pour garantir l'intégrité de notre analyse.

Implications pour le Nettoyage des Données :

Il est crucial d'identifier et d'éliminer les valeurs aberrantes afin d'assurer la précision de notre analyse.

L'importance de traiter les valeurs nulles ne peut être sous-estimée, car elles sont essentielles pour garantir la fiabilité de nos conclusions.

Démarche Méthodologique d'Analyse de Données - Préparation des données

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 200137 entries, 0 to 200136
Data columns (total 18 columns):
#   Column                Non-Null Count  Dtype  
---  -
0   id                     200137 non-null int64  
1   type_emplacement      200137 non-null object 
2   domanialite           200136 non-null object 
3   arrondissement        200137 non-null object 
4   complement_adresse    30902 non-null object 
5   numero                0 non-null     float64
6   lieu                  200137 non-null object 
7   id_emplacement        200137 non-null object 
8   libelle_francais      198640 non-null object 
9   genre                 200121 non-null object 
10  espece                 198385 non-null object 
11  variete                36777 non-null object 
12  circonference_cm       200137 non-null int64  
13  hauteur_m              200137 non-null int64  
14  stade_developpement   132932 non-null object 
15  remarquable            137039 non-null float64
16  geo_point_2d_a         200137 non-null float64
17  geo_point_2d_b         200137 non-null float64
dtypes: float64(4), int64(3), object(11)
memory usage: 27.5+ MB
```

	Nombre manquant	Pourcentage manquant (%)
id	0	0.00
type_emplacement	0	0.00
domanialite	1	0.00
arrondissement	0	0.00
complement_adresse	169235	84.56
numero	200137	100.00
lieu	0	0.00
id_emplacement	0	0.00
libelle_francais	1497	0.75
genre	16	0.01
espece	1752	0.88
variete	163360	81.62
circonference_cm	0	0.00
hauteur_m	0	0.00
stade_developpement	67205	33.58
remarquable	63098	31.53
geo_point_2d_a	0	0.00
geo_point_2d_b	0	0.00



Démarche Méthodologique d'Analyse de Données - Préparation des données

Importation des données :

Utilisation de bibliothèques Python (Pandas, Matplotlib) pour importer et afficher les données.


Vérification initiale :

Vérification des dimensions, des types de colonnes et premier aperçu des statistiques descriptives des variables numériques tel que les valeurs minimal et maximal, la moyenne et les quartiles.

Identification des valeurs manquantes :


Calcul des valeurs manquantes pour chaque colonne et leur impact.

Démarche Méthodologique d'Analyse de Données - Préparation des données



Démarche Méthodologique d'Analyse de Données - Préparation des données

Distribution de la Hauteur des Arbres (Avant Nettoyage)





Démarche Méthodologique d'Analyse de Données - Nettoyage des données 1/2

Identification des Valeurs Aberrantes :

- **Approche métier** : Définition des seuils basés sur les records mondiaux pour la circonférence et la hauteur des arbres. C'est un séquoia géant (Sequoiadendron giganteum) mesurant 115 mètres avec une circonférence de 31,3 mètres qu'on peut voir dans le parc national de Sequoia, en Californie.
- **Méthode Interquartile (IQR)** : Utilisation de cette méthode statistique pour identifier les valeurs aberrantes basées sur les quartiles de la distribution.

Suppression des Valeurs Aberrantes :

Combinaison et suppression des outliers identifiés par les deux méthodes.



Démarche Méthodologique d'Analyse de Données - Nettoyage des données 2/2


Suppression des Valeurs Égales à Zéro :

Suppression des valeurs de circonférence et de hauteur égales à zéro.


Gestion des Valeurs Manquantes :

- **Suppression des Colonnes :** Suppression des colonnes avec un pourcentage très élevé de valeurs manquantes (``numero`` (100%), ``complement_adresse`` (85%), ``variete`` (82%)).
- **Imputation des Valeurs Manquantes :** Les valeurs manquantes dans la colonne ``remarquable`` (32%) ont été remplacées par 0, et celles dans la colonne ``stade_developpement`` (34%) ont été imputées par la valeur la plus fréquente (mode).

Démarche Méthodologique d'Analyse de Données - Conclusion



Démarche Méthodologique d'Analyse de Données - Conclusion





Démarche Méthodologique d'Analyse de Données - Conclusion

La préparation et le nettoyage rigoureux des données sont essentiels pour obtenir des résultats fiables et pertinents. Voilà ce que permettent ces étapes :

- **Assurer l'exactitude des analyses** : En éliminant les anomalies et en comblant les lacunes, les données sont plus représentatives de la réalité.
- **Améliorer la qualité des décisions** : Des données propres et précises mènent à des conclusions plus solides et à des recommandations mieux informées.
- **Optimiser les ressources** : En disposant de données fiables, les tournées d'entretien des arbres peuvent être planifiées de manière plus efficace, réduisant les coûts et les efforts.



Synthèse de l'Analyse de Données - Principales Découvertes 1/2

Distribution des circonférences des arbres :

- **Concentration autour de 20 cm** : Un pic notable autour de 20 cm indique que beaucoup d'arbres ont une circonférence proche de cette valeur.
- **Distribution étendue** : La distribution est relativement large, avec une concentration notable autour de 70 à 80 cm.
- **Diminution progressive** : Après 100 cm, la fréquence diminue progressivement, mais il existe encore des arbres avec des circonférences allant jusqu'à 250 cm.



Synthèse de l'Analyse de Données - Principales Découvertes 2/2

Distribution des hauteurs des arbres :


- **Médiane** : La médiane de la hauteur des arbres est de 10 m, ce qui signifie que 50 % des arbres ont une hauteur inférieure ou égale à 10 m.
- **Plage interquartile (IQR)** : La majorité des hauteurs des arbres se situe entre 6 m et 12,5 m.
- **Valeurs extrêmes** : Les hauteurs varient de 1 m à 22 m sans être considérées comme des valeurs aberrantes.



Synthèse de l'Analyse de Données - Statistiques Clés

- Médiane de la circonférence des arbres : 80 cm
- Médiane de la hauteur des arbres : 10 m
- Écart-type de la circonférence des arbres : 50,37 cm
- Écart-type de la hauteur des arbres : 4,58 m

Synthèse de l'Analyse de Données - Distribution des Arbres par Arrondissement





Synthèse de l'Analyse de Données - Distribution des Arbres par Arrondissement


Analyse du Graphique :

- Les arrondissements les plus arborés sont le 16ème, le 13ème, le 20ème et le 12ème.
- Les arrondissements les moins arborés sont les 3ème, 2ème et les Hauts-de-Seine.

Implications pour les Tournées d'Entretien :

- **Planification des Ressources :** Les arrondissements avec une forte concentration d'arbres nécessitent plus de ressources et des tournées plus fréquentes.
- **Efficacité des Interventions :** Les arrondissements avec moins d'arbres peuvent avoir des tournées moins fréquentes, permettant une redistribution des ressources.
- **Optimisation des Itinéraires :** Les itinéraires peuvent être optimisés pour minimiser le temps de déplacement et maximiser le temps d'entretien.

Synthèse de l'Analyse de Données - Distribution des Domaines des Arbres





Synthèse de l'Analyse de Données - Distribution des Domaines des Arbres


Analyse du Graphique :

- La majorité des arbres sont situés dans des alignements.
- Les jardins et les cimetières sont les seconds domaines les plus courants.

Implications pour les Tournées d'Entretien :

- **Planification des Ressources** : Les alignements nécessitent des ressources importantes pour l'entretien, suivis des jardins et cimetières.
- **Efficacité des Interventions** : Les domaines moins représentés peuvent avoir des tournées moins fréquentes, permettant de concentrer les efforts sur les alignements et les jardins.
- **Optimisation des Itinéraires** : Les itinéraires peuvent être optimisés en regroupant les interventions par type de domaine, réduisant les déplacements inutiles.

Synthèse de l'Analyse de Données - Localisation Géographique des Arbres Remarquables





Synthèse de l'Analyse de Données - Localisation Géographique des Arbres Remarquables

Analyse de la carte :

- Les arbres remarquables sont principalement concentrés dans les 12ème, 16ème arrondissements et le Bois de Vincennes.
- Les autres arrondissements ont une distribution plus clairsemée d'arbres remarquables.

Implications pour les Tournées d'Entretien :

- **Planification des Ressources :** Les zones avec une forte concentration d'arbres remarquables nécessitent une attention et des ressources particulières pour leur entretien.
- **Efficacité des Interventions :** Les interventions spécifiques pour les arbres remarquables doivent être planifiées soigneusement pour préserver leur santé et leur valeur.
- **Optimisation des Itinéraires :** Les itinéraires d'entretien peuvent être optimisés en se concentrant d'abord sur les zones avec une densité élevée d'arbres remarquables, minimisant ainsi les déplacements.



Synthèse de l'Analyse de Données - Implications pour l'Optimisation des Tournées

Planification des ressources :

Les données sur les circonférences et hauteurs des arbres permettent de mieux planifier les ressources nécessaires pour l'entretien, en se concentrant sur les arbres les plus grands et les plus larges.

Priorisation des interventions :

Les arbres identifiés comme remarquables ou nécessitant une attention particulière peuvent être priorisés dans les tournées d'entretien.

Efficacité opérationnelle :

L'analyse permet de réduire les trajets inutiles en optimisant les itinéraires en fonction des caractéristiques des arbres.